Fallbeispiel – AI Expert

Datensatz für Beispiel:



3D8026C4.zip

1. Ziel

Sie bearbeiten **ein Fallbeispiel** mit einem SMS-Datensatz (HAM/SPAM).

Es gibt zwei **Fokusbereiche**:

1. **Klassisches Machine Learning & Data Science**
2. **GenAI & LLM (inkl. Agentic AI)**

Wir erwarten:

- **Code-Lösungen** für die explizit als solche gekennzeichneten Aufgaben
- Die Code-Lösungen sollen **präsentiert** werden und bilden die Grundlage für eine **offene Diskussion**.

2. Ablauf

1. Sie erhalten:
   - den SMS-Datensatz
   - diese Aufgabenbeschreibung
2. Sie senden uns **vor dem Gespräch**:
   - Ihren Code
   - eine kurze Ausführungsbeschreibung (z. B. README)
   - eine requirements.txt
3. Im **Gespräch / Hearing (ca. 15 Minuten)**:
   - Rückfragen & „Challenge“ zu Ihrem Code
   - Fachdiskussion zu Architektur- und Konzeptthemen

3. Technische Rahmenbedingungen

Klassisches ML & Data Science

- Vollständige Python-Lösung (lokal lauffähig, ohne Nutzung externer ML- oder LLM-Dienste)
- Python 3.x, gängige Open-Source-Bibliotheken (z. B. pandas, numpy, scikit-learn, nltk/spacy, …)
- Bitte beilegen:
  - requirements.txt
  - kurze Anleitung zur Ausführung (z. B. in einem README)

GenAI & LLM

- Nutzung externer Dienste (z. B. LLMs, Embeddings-APIs) ist möglich und erwünscht
- Bitte dokumentieren:
  - verwendete APIs/Modelle/Dienste
  - verwendete Bibliotheken
  - wie Ihre Lösung grundsätzlich ausgeführt und nachvollzogen werden kann (z. B. Konfiguration von API Keys, typische Aufrufbeispiele)

4. Aufgaben – Codelösungen

4.1 Klassisches ML & Data Science (Code)

1. **Analyse der Texte – häufigste Wörter**
   - Welche Wörter kommen in den SMS am häufigsten vor?
2. **HAM vs. SPAM – Unterschiede in der Wortwahl**
   - Gibt es markante Unterschiede in der Wortwahl zwischen HAM und SPAM?
   - Welche Wörter sind besonders typisch für SPAM bzw. HAM?
3. **Häufige Wortgruppen**
   - Welche Wortgruppen (z. B. Bigrams/Trigrams) treten besonders häufig gemeinsam auf?
4. **SPAM/HAM-Klassifikationsmodell**
   - Entwickeln Sie ein Modell, das SMS als SPAM oder HAM klassifiziert.
   - Bitte inkl. kurzer Beschreibung von:
     - der Textrepräsentation
     - dem gewählten Modell
     - der Evaluierung

4.2 GenAI & LLM (Code)

1. **Semantisches Clustering der SMS**
   - Entwickeln Sie eine Logik, die SMS auf Basis **semantischer Ähnlichkeit** in Cluster einteilt.
   - Hinweis: Es wird eine Lösung mit **LLMs/Embeddings** erwartet (z. B. Vektorrepräsentationen der SMS, Clustering-Verfahren).

5. Einreichung

Bis zu 24 Stunden vor dem vereinbarten Termin senden Sie bitte:

- Ihren **Code** zu allen Aufgaben mit der Kennzeichnung „Code“ bzw. „Erwartung: Codelösung“
- requirements.txt und eine kurze Ausführungsanleitung (z. B. README)
- Optional: kurze Skizzen oder Notizen zu den Diskussionsthemen